

Probability Prepared

① 概率基础

1. 样本空间，概率测度。

$$\rightarrow A \cup B = \Omega, A \cap B = \emptyset, A - B (\text{w} \notin A, w \in B) = \frac{w}{\Omega}.$$

$$\rightarrow A \cap B = \emptyset = \text{互不相容} / \text{互斥}, A \cup B = \Omega, A \cap B = \emptyset = \text{逆事件} / \text{对立} \boxed{A/B}$$

→ 概率加法。不相容事件 (e.g. $\dots \rightarrow$ 等可能)。

$$\rightarrow \text{对不相容事件}, P(\bigcup A_k) = \sum P(A_k) \quad (\text{有限个})$$

$$\hookrightarrow \text{若 } A \subset B, \text{ 则 } A - B \text{ 不相容}, P(B - A) = P(B) - P(A)$$

$$\rightarrow P(\bar{A}) = 1 - P(A), \text{ 且 } P(A\bar{B}) = P(A(1-B)) = P(A - AB) = P(A) - P(AB).$$

$$\rightarrow \text{加法定律: } P(A \cup B) = P(A) + P(B) - P(AB)$$

2. 概率型

→ 还原问题 (4张同色扑克牌, 至少抽到1张同色牌)。

$$(\text{设 } A_i = \{\text{抽到 } i \text{ 张}\}), P(A_i) = \frac{A_i^3}{A_4^4} = \frac{1}{4}.$$

$$P(A_i A_j) = \frac{A_2^2}{A_4^4} = \frac{1}{3 \times 4}, P(A_i A_j A_k) = \frac{1}{A_4^4} = \frac{1}{2 \times 3 \times 4}.$$

$$\begin{aligned} \text{求 } P(\text{至少} - 1) &= P(A_1 \cup A_2 \cup A_3 \cup A_4) = \sum P(A_i) - \sum P(A_i A_j) + \sum P(A_i A_j A_k) - P(A_1 A_2 A_3 A_4) \\ &= 4 \times \frac{1}{4} - C_4^2 \cdot \frac{1}{4 \times 3} + C_4^3 \times \frac{1}{4 \times 3 \times 2} - \frac{1}{4 \times 3 \times 2 \times 1} = 1 - \frac{1}{2!} + \frac{1}{3!} - \frac{1}{4!} \end{aligned}$$

$$\rightarrow \text{几何概率型}, P(A) = \frac{S_A}{S_\Omega}, \text{ 常画坐标系图解}.$$

3. 条件概率

$$\rightarrow P(A|B) = \frac{P(AB)}{P(B)}, B \text{ 发生情况下 } A \text{ 发生的概率}.$$

$$\rightarrow \text{满足加性, } P(\bigcup A_k | B) = \sum P(A_k | B).$$

$$\rightarrow \text{全概率公式, } P(A) = \sum P(A|B_i) P(B_i).$$

$$\rightarrow \text{Bayes 公式, } P(B_i | A) = \frac{P(A|B_i) P(B_i)}{P(A)} = \frac{P(A|B_i) P(B_i)}{\sum P(A|B_j) P(B_j)}.$$

4. 独立性

$$\rightarrow P(AB) = P(A)P(B) \text{ 事件为独立.}$$

→ 独立性与不相容无关, 且不同时成立。

$$\rightarrow A_1, A_2, A_3 \text{ 相互独立: } P(A_i A_j) = P(A_i)P(A_j) \text{ 互斥, } \text{ 且 } P(A_1 A_2 A_3) = P(A_1)P(A_2)P(A_3) \text{ 也成立.}$$

② 随机变量.

1. 离散随机变量

$\rightarrow F(x) = P\{X \leq x\}$ 为分布函数(cdf).

\rightarrow 各类分布:

\hookrightarrow 单点分布, $P\{X=c\} = 1$.

\hookrightarrow 双点分布(伯努利), $P\{X=1\} = p, P\{X=0\} = 1-p$.

\hookrightarrow n重伯努利^(有n次) \rightarrow 2次, $P\{X=k\} = C_n^k p^k (1-p)^{n-k}$, $\text{且 } X \sim B(n, p)$

\hookrightarrow n重伯, 直到首次成功. \rightarrow 用^(用S表示): $P\{X=k\} = (1-p)^{k-1} \cdot p, (k=1, 2, 3)$

\hookrightarrow 直到成功r次, 第r次分布: $P(k) = C_{k-1}^{r-1} p^r (1-p)^{k-r} (k=1, 2, 3)$.

\hookrightarrow 对于有n件, r是/n+1. 无重复抽样, 抽出了k个样本.

$P\{X=k\} = \frac{C_r^k \cdot C_{n-r}^{m-k}}{C_n^m}, k=1, 2, \dots, m. (\text{超N}(\bar{z}))$.

\hookrightarrow 泊松分布: $P\{X=k\} = \frac{\lambda^k}{k!} e^{-\lambda}, k=0, 1, \dots, R$ 且 $X \sim P(\lambda)$

在单位时间内随机事件发生的次数.

\hookrightarrow 泊松流: $X \sim P(\lambda t), P\{X=k\} = \frac{(\lambda t)^k}{k!} e^{-\lambda t}$.

\rightarrow 泊松化: 对 $\frac{1}{n} \rightarrow np = \lambda$, 则有: $C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}$
仅当n足够大, p足够小. \Rightarrow 白噪声

2. 连续随机变量.

\rightarrow $\begin{cases} \text{离散} & \{ \text{pmf, 分布函数: cdf, 分布函数} \} \\ \text{连续} & \{ \text{pdf, 密度函数; cdf, 分布函数} \} \end{cases}$

$\rightarrow F(x) = \int_{-\infty}^x f(t) dt, f(t) \geq 0 \forall t$, 为密度函数. (X 本身不连续)


且 $\int_{-\infty}^{\infty} f(t) dt = 1, f(x) = F'(x)$.

且任一点, $P\{X=c\} = 0$ 但不代表不发生事件 (因为 $\lambda - p$ 偏向于零).

\rightarrow 对 $F(x_p) = p$, \Rightarrow $f(x_p)$ 为 $f(x)$ 的概率.

\rightarrow 正态分布: $f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$.

且 $X \sim N(\mu, \sigma^2)$. 均于 μ 对称, 且取值 $\frac{1}{\sqrt{2\pi}\sigma}$.



↪ $\mu=0$, $\sigma^2=1$ 表示服从 $\varphi(x)$ 分布， $\phi(x)$ 累积。

且对任意 $\{x\}$, $X \sim N(\mu, \sigma^2)$, 有 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$

↪ ex. 若 $X \sim N(50, 100)$, $P\{X \geq 70\} = \phi\left(\frac{70-50}{10}\right) = \phi(2)$.

↪ 36.15%
↪ $P\{e^{-36} < X \leq e^{+36}\} = 99.74\%$.

→ 均匀分布: 对 $f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其它} \end{cases}$ 的均匀分布, $X \sim U(a, b)$.

↪ 同理可知 $F(x) = \frac{x-a}{b-a}$ 为均匀分布。

→ 指数分布. 对 $f(x) = \lambda e^{-\lambda x}$ ($x > 0$), 表示 $\lambda > 0$ 的指数分布。

设 $X \sim EXP(\lambda)$, 则 $f(x) = 1 - e^{-\lambda x}$ ($x > 0$).

↪ 相应的分布函数: 对 $X \sim P(\lambda t)$, 表示 T 为第一个质数出现时间,

$P\{T > t\} = P\{X = 0\} = e^{-\lambda t}$, $\therefore F(t) = P\{T \leq t\} = 1 - P\{T > t\} = 1 - e^{-\lambda t}$
即 $T \sim EXP(\lambda)$.

↪ 具有记忆性, 即为平均寿命 (θ) .

↪ 具有记忆性, $P\{X > s+t | X > s\} = P\{X > t\}$.

3. 随机变量的函数。

→ 对于离散型, 要点在于找到对应的事件.

$$\text{ex. } T = (X-1)^2, \quad \begin{array}{c|cccc} X & -1 & 0 & 1 & 2 \\ \hline P_k & 0.2 & 0.3 & 0.1 & 0.4 \end{array} \Rightarrow \begin{array}{c|ccc} T & 4 & 1 & 0 \\ \hline P_k & 0.2 & 0.7 & 0.1 \end{array} \text{ (舍弃 0)}.$$

→ 对连续型, 对 $y = g(x)$, $F_T(y) = P\{T \leq y\} = P\{g(x) \leq y\} = F_x(g^{-1}(y))$

若求 $f_T(y)$, $\therefore f_T(y) = F'_T(y) = f_x(g^{-1}(y)) \cdot |(g^{-1}(y))'|$.

↪ 特别地 $aX+b \sim N(a\mu+b, (a\sigma)^2)$.

↪ 且对有 $y = g(x) = x^2$ 为简单例 (注意 y 关于 x 的, $g(x)$ 为 y 的函数).

$\therefore f_T(y) = \sum |h_i'(y)| \cdot f(h_i(y))$, $h_1(y), h_2(y), \dots$ 为 y 的反像. ($\nexists P\{f_T(y) = 0\}$)

→ 任何分布类型的分布 $f_T(y)$ 为 $f_T(y)$ 分布. ($Z = F(x)$, $\therefore Z \sim U(0, 1)$).

(反过来地, $U \sim U(0, 1)$, $X = F^{-1}(U)$, $\therefore X$ 的分布类型为 $F(x)$).

↪ ex. $X \sim EXP(\lambda)$, $T = F(X)$, $\therefore F_T(y) = \int_0^y 1 - e^{-\lambda x} dx = 1 - e^{-\lambda y}$.

$\therefore y \leq 0, F_T(y) = 0$; $y \geq 1, F_T(y) = 1$. $\therefore 0 < y < 1, F_T(y) = P\{1 - e^{-\lambda x} \leq y\} = P\{X \leq -\frac{1}{\lambda} \ln(1-y)\} = 1 - e^{-\lambda[-\frac{1}{\lambda} \ln(1-y)]} = y$.

③ 联合分布

1. 基础

→ 离散: $P\{X=x_i, Y=y_j\} = P(X=x_i, Y=y_j) = P_{ij}$. 或用卷积公式.

$$P\{X=x_i\} = P(\{X=x_i\} \cap \Omega) = \sum_{j=1}^{\infty} P\{X=x_i, Y=y_j\} = \sum_{j=1}^{\infty} P_{ij} = P_i.$$

→ 连续: $f(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$, 且 $f(u, v) \geq 0$, $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) = 1$.

$$\text{且 } f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$$

$\exists z f(x, y) = k e^{-x-y}$. 若 k , 则 $f(x, y)$ 为常数.

→ 边缘密度, $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$, $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$.

→ 若 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$.

其中 $|\rho| < 1$. \Rightarrow 因为 $\rho = 0$ 时, X, Y 才互独立.

→ 二维均匀分布, $f(x, y) = \begin{cases} 1/A, & (x, y) \in G \\ 0, & \text{其它.} \end{cases}$

→ 独立性: 若 $f(x, y) = f_X(x) \cdot f_Y(y)$, 则 X, Y 相互独立.

或对多维型, $P\{X=x_i, Y=y_j\} = P\{X=x_i\} \cdot P\{Y=y_j\}$ 对 i, j 成立.

或对连续型, $f(x, y) = f_X(x) \cdot f_Y(y)$. 则成立.

（）又如, 已知独立, $P_{XY} \propto f_X(x) \cdot f_Y(y) \Leftrightarrow f(x, y)$.

2. 条件事件分布,

对于多维型, $P\{X=x_i | Y=y_j\} = \frac{P\{X=x_i, Y=y_j\}}{P\{Y=y_j\}}$.

$P_{X|Y}(x_i | y_j) = P\{X=x_i, Y=y_j\}$. 为条件概率的单值.

而对于连续型, $f_{X|Y}(x_i | y) = \frac{f(x, y)}{f_Y(y)}$, 为条件密度.

2D $F_{X|Y}(x | y) = \int_{-\infty}^x f_{X|Y}(u | y) du$, 为条件分布.

（）连续全概率: $f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X}(y | x) f_X(x) dx$.

2. 联合分布, 及其与统计推断

1. 一维随机变量的分布. (连续型)

$$\begin{aligned} P\{Y \leq z\} &= P\{Z \leq z\} = P\{X + Y \leq z\} = \iint_{x+y \leq z} f(x, y) dx dy \\ &= \int_{-\infty}^{+\infty} dy \int_{-\infty}^{z-y} f(x, y) dx. \end{aligned}$$

若 X 与独立时推导得卷积公式, $f_Z(z) = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$.

令 $Z = a_1 X_1 + a_2 X_2 + \dots + a_n X_n \sim N(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$,
其中 $\text{均值 } \bar{X}_i = X_i - N(\mu_i, \sigma_i^2)$.

$\rightarrow Z = X + Y$ 的分布 (参数型).

$$\begin{aligned} \text{若 } P\{X=i\} = p_i, P\{Y=j\} = q_j, \text{ 则 } P\{Z=k\} &= \sum_{i+j=k}^{k-1} P\{X=i\} \cdot P\{Y=j\} \\ &= \sum_{j=1}^{k-i} P\{X=k-j\} \cdot P\{Y=j\}. \quad (\text{参数型}) \end{aligned}$$

$\rightarrow Z = \frac{X+Y}{\sqrt{2}}$ 分布, $F_Z(z) = P\{X+Y \leq z\} = \iint_{x+y \leq z} f(x,y) dx dy$

令 Jacobi, $x = x(u,v), y = y(u,v), Oxy \rightarrow O'uv$.

$$P\{Z \leq z\} = \left| \begin{array}{cc} \frac{\partial(x,y)}{\partial(u,v)} & \\ \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{array} \right|, \quad P\{ \iint f(x,y) dx dy \} = \iint f[x(u,v), y(u,v)] \cdot |J| du dv.$$

$$P\{Z \leq z\} = \int_0^z \left(\int_{-\infty}^y f(u,y) dy \right) du$$

$$P\{f_Z(z) = \int_{-\infty}^z f(z,y) dy\}.$$

$\rightarrow X \sim F_X(x), Y \sim F_Y(y)$ 且 X, Y 相互独立, 则:

$$F_{\max}(z) = P\{\max(X, Y) \leq z\} = P\{X \leq z, Y \leq z\} = P\{X \leq z\} \cdot P\{Y \leq z\} = F_X(z) \cdot F_Y(z).$$

$$\begin{aligned} F_{\min}(z) &= P\{\min(X, Y) \leq z\} = 1 - P\{\min(X, Y) > z\} = 1 - P\{X > z\} \cdot P\{Y > z\} \\ &= 1 - (1 - F_X(z))(1 - F_Y(z)) = 1 - (1 - F_X(z))(1 - F_Y(z)). \end{aligned}$$

且 $Z \sim f_Z(z)$. 因 X, Y 独立同分布, $P\{f_{\max}(z) = F(z)\} = F^2(z)$, $f_{\min}(z) = 1 - (1 - F(z))^2$.

故, 得 $f_{\max}(z) = n f(z) [F(z)]^{n-1}$, $f_{\min}(z) = n f(z) [1 - F(z)]^{n-1}$.

又 $\bar{X}_{(1)} = \min(X_1, \dots, X_n)$, $X_{(n)} = \max(X_1, \dots, X_n)$.

$$\rightarrow \text{求 } P\{X_{(k)} \leq x\}: P\{x \leq X_{(k)} \leq x+dx\} = \underbrace{\frac{n!}{(k-1)! \cdot x^{k-1} (n-k)!} F^{k-1}(x) [1-F(x)]^{n-k} f(x) dx}_{\text{对 } f_k(x) dx, P\{f_k(x) = 1\}}.$$

\rightarrow 若 $\bar{X} = X_{(n)}$, $\bar{Y} = X_{(1)}$, $\bar{Z} = X_{(n-1)}$.

$$\begin{aligned} P\{v \leq X_{(n)} \leq u, u \leq X_{(1)} \leq u+du\} &= f(u, v) du dv \\ &= n(n-1) [F(u) - F(v)]^{n-2} f(u) du f(v) dv. \end{aligned}$$

$$P\{f(u, v) = n(n-1) f(u) f(v) [F(u) - F(v)]^{n-2}, u \geq v\}.$$

③ 隨機變量的數字特徵

1. 期望

→ 离散型，期望： $E(X) = \sum x_k p_k = \sum x_k P\{X=x_k\}$

連續型，期望： $E(X) = \int_{-\infty}^{\infty} x f(x) dx$. ($\int_{-\infty}^{\infty} = \infty$ ， $f(x)$ 不在 \mathbb{R} 上).

→ 當 t 不為 $r.v.$ 滿足 $P\{x \geq t\} = 1$ ，且 $E(x) < t$ ， $P\{x \geq t\} \leq \frac{E(x)}{t}$.

$$\hookrightarrow \text{离散型推导: } E(x) = \sum x p(x) = \sum_{x < t} x p(x) + \sum_{x \geq t} x p(x) \\ \geq \sum_{x \geq t} x p(x) \geq \sum_{x=t}^{\infty} t p(x) = t P\{x \geq t\},$$

$\therefore P\{x \geq t\} \leq \frac{E(x)}{t}$ 諸多大數性質.

→ 多重的數字期望：
 | 离散型： $E(Y) = E(g(x)) = \sum g(x_k) \cdot p_k$ (不看 x)

| 連續型： $E(Y) = E(g(x)) = \int_{-\infty}^{\infty} g(x) f(x) dx$

且 \exists 扩展到高維：
 | 离散型： $E(z) = E(g(x, y)) = \sum_{i=1}^m \sum_{j=1}^n g(x_i, y_j) \cdot p_{ij}$.

| 連續型： $E(z) = E(g(x, y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$.

$$\text{e.g. } E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy.$$

→ 數學期望的性質： $E(cx) = cE(x)$. / $\forall c \in \mathbb{R}, E(x+y) = E(x) + E(y)$.

$$\text{且 } X, Y \text{ 獨立, } E(XY) = E(X)E(Y).$$

$$\text{且 } a_i \text{ 为常数, } X_i \text{ 为 r.v., } \therefore E(\sum a_i X_i) = \sum a_i E(X_i).$$

2. 方差

→ $V_{ar}(X) = D(X) = E((X - E(X))^2)$. 而 $\sqrt{D(X)}$ 不是方差.

$$\hookrightarrow \text{通用形式推导: } D(X) = E((X - E(X))^2) = E(X^2) - 2E(X)E(X) + [E(X)]^2 \\ = E(X^2) - 2E(X) \cdot E(X) + [E(X)]^2 \quad (\text{E(X) 为常数}) \\ = E(X^2) - [E(X)]^2.$$

→ 常用分布的期望与方差推导 ($p(\lambda), b(n, p), U(a, b), \exp(\frac{1}{\theta}), N(\mu, \sigma^2)$)

$$\square p(\lambda). \quad \text{若 } P\{X=k\} = \frac{\lambda^k}{k!} e^{-\lambda}. \quad \text{则 } E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \cdot \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ = e^{-\lambda} \cdot \lambda \cdot e^{-\lambda} = \lambda.$$

$$E(X^2) = E[X(X-1)+X] = \sum k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} + E(X) \\ = e^{-\lambda} \cdot \lambda^2 \cdot \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} + \lambda = \lambda^2 + \lambda.$$

$$\text{P} D(X) = \lambda^2 + 1 - (\lambda)^2 = \lambda.$$

$$[2] b(n, p). \quad \text{P} P(X=k) = C_n^k \cdot p^k \cdot (1-p)^{n-k}$$

由子 P 为独立随机变量, $E(X) = E(X_1 + X_2 + \dots + X_n)$
 $= n \cdot E(X_1) = np$

$$D(X) = D(X_1 + \dots + X_n) = n \cdot D(X_1) = n \cdot [(1-p)^2 \cdot p + (0-p) \cdot (1-p)] \\ = np(1-p).$$

$$[3] U(a, b). \quad \text{P} f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他.} \end{cases}$$

$$\text{P} E(X) = \frac{a+b}{2}, \quad E(X^2) = \int_a^b \frac{x^2}{b-a} dx = \frac{1}{3} (b^3 - a^3) / (b-a) = \frac{a^2 + ab + b^2}{3}.$$

$$D(X) = E(X^2) - [E(X)]^2 = \frac{(b-a)^2}{12}.$$

$$[4] EXP(\frac{1}{\theta}). \quad \text{P} f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & x \leq 0. \end{cases}$$

$$E(X) = \int_0^\infty \frac{x}{\theta} \cdot e^{-\frac{x}{\theta}} dx, \quad \text{令 } m = -\frac{x}{\theta}, \quad dm = -\frac{1}{\theta}.$$

$$\int_0^\infty \theta \cdot m \cdot e^m dm = \int_{-\infty}^0 \theta e^m dm = 0.$$

$$E(X^2) = \int_0^\infty \frac{x^2}{\theta} \cdot e^{-\frac{x}{\theta}} dx = \int_{-\infty}^0 m^2 \cdot \theta^2 \cdot e^m dm = -2 \int_{-\infty}^0 m \cdot \theta^2 \cdot e^m dm \\ = 2 \int_{-\infty}^0 \theta^2 e^m dm = 2\theta^2.$$

$$\text{P} D(X) = E(X^2) - [E(X)]^2 = \theta^2.$$

由 $E(\frac{|X-\mu|}{\sigma})$, P 为 X ,

$$\int_{-\infty}^{+\infty} \frac{|t|}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = 2 \int_0^\infty \frac{t}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \\ = \sqrt{\frac{2}{\pi}}.$$

$$\rightarrow \text{方差的性质} \rightarrow D(c) = 0, \quad D(cx) = c^2 D(x),$$

$$D(x+t) = D(x) + D(t) + 2 \text{Cov}(x, t). \quad \text{由 } D(x+t) = D(x) + D(t),$$

$$[3] \text{方差 } D(x-t) = D(x) + D(t) - 2 \text{Cov}(x, t).$$

由 P P P P .

$$\rightarrow \text{由 } D(x) = \mu^2, \quad D(x) = \sigma^2, \quad \text{P} \exists \forall \varepsilon > 0, \quad P\{|x-\mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}.$$

$$\hookrightarrow \text{推导: } \forall t = (x-\mu)^2, \quad E(t) = E(x - E(x))^2 = D(x) = \sigma^2.$$

$$\text{P} \text{ 由 } \text{Markov}, \quad \text{得 } P\{|x-\mu| \geq \varepsilon\} = P\{t \geq \varepsilon^2\} \leq \frac{E(t)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}.$$

3. 协方差

$$\rightarrow \text{协方差 } \text{Cov}(x, t) = E[(x - E(x))(t - E(t))] = E(Xt) - E(x)E(t).$$

$$\hookrightarrow \text{性质: } \text{Cov}(ax, bt) = ab \text{Cov}(x, t).$$

$$\text{Cov}(x_1 + x_2, t) = \text{Cov}(x_1, t) + \text{Cov}(x_2, t).$$

$$\text{性质: } \text{若 } U = a + \sum^n b_i x_i, \quad V = c + \sum^m d_j y_j,$$

$$\text{Cov}(U, V) = \sum^n \sum^m b_i d_j \text{Cov}(x_i, y_j).$$

→ 两个变量独立关系: $\text{Cov}(X, Y) \neq 0$, 则 X, Y 不独立.

$\text{Cov}(X, Y) = 0$, 则 X, Y 不一定独立. (这例子不成立的简单理解),
即 $\text{Cov}(X, Y) = 0 \Leftrightarrow \text{独立}$.

→ 离散元量标准化后 X, Y : $X^* = \frac{X - E(X)}{\sqrt{D(X)}}$, $Y^* = \frac{Y - E(Y)}{\sqrt{D(Y)}}$.

且 $P_{XY} = \text{Cov}(X^*, Y^*) = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)} \sqrt{D(Y)}}$ 为 X, Y 的相关系数.

↳ 因有: $|P_{XY}| \leq 1$, 且当 $|P_{XY}| = 1$, 则 Y 与 X 是完全线性关系.

$\begin{cases} P_{XY} = 1: \text{正相关} \\ P_{XY} = -1: \text{负相关}, \text{且 } P_{XY} = 0 \text{ 为不相关.} \end{cases}$

→ 练. $E(X^k)$ —— k 次方的矩, $E(X)$ 为 1 次方的矩.

$E((X - E(X))^k)$ —— k 次方的中心矩, $D(X)$ 为 2 次方的中心矩.

$E[(X - E(X))^k (Y - E(Y))^l] = k+l$ 次方的联合矩, $\text{Cov}(X, Y)$ 为 2 次方的联合矩.

⑤ 大数定律 中心极限定理

1. 大数定律

→ 回到频率: n 次试验, n_A 次事件发生, 则 $\frac{1}{n} \sum_{i=1}^n \xi_i = \frac{n_A}{n} = p$. (频率)

→ 设多, $\xi_1 - \xi_n$ 是随机变量, $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|\xi_n - \bar{\xi}| \geq \varepsilon\} = 0$,

RM 律 ξ_n 依概率收敛于 $\bar{\xi}$, 记为 $\xi_n \xrightarrow{P} \bar{\xi}$.

随着 n ↑, $\xi_n - \bar{\xi}$ 变大的概率↓.

组合

→ 则得弱大数定律, $\lim_{n \rightarrow \infty} P\{|\frac{n_A}{n} - p| \geq \varepsilon\} = 0$. ($P(A) = p$). (即 $\xi_n \xrightarrow{P} p$).

→ 加加弱大数定律, $\lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n X_i - \mu| \geq \varepsilon\} = \lim_{n \rightarrow \infty} P\{|\bar{X} - \mu| \geq \varepsilon\} = 0$.

(对于 $E(X_i) = \mu$, $D(X_i) = \sigma^2$ 的独立 r.v. 有 D.E.).

(利用 Chebychev 不等式, $P\{|\xi - E(\xi)| \geq \varepsilon\} \leq \frac{D(\xi)}{\varepsilon^2}$. (算术平均值 \rightarrow 期望)).

→ 强大数定律, 对独立同分布 $\{X_n\}$. ($E(X_1) = \mu$, 端即 $E(X_k) \neq E(X_i)$, 互不相))

则也有 $\lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{k=1}^n X_k - \mu| \geq \varepsilon\} = 0$.

若对 E 存在时, 才有整体基期望对期望
收敛性 (任一收敛/尾端分布不考虑).

2. 中心极限定理

→ 对 $\{X_n\}$ 为独立 r.v. $\exists \mu, \sigma^2$, $E(X_n) = \mu_n, D(X_n) = \sigma_n^2$ 且 $\bar{\sigma}_n \neq 0$.

$\sum Z_n = \frac{\sum X_k - E(\sum X_k)}{\sqrt{D(\sum X_k)}}$, 当 X_k 作用均值 2 小时. $\lim_{n \rightarrow \infty} Z_n \sim N(0, 1)$.

→ 中心极限定理. Z_n 的分布函数 $\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left\{ \frac{\sum X_k - E(\sum X_k)}{\sqrt{\sum \sigma_k^2}} \leq x \right\}$

$$= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \phi(x).$$

RM 律 $\{X_n\}$ 服从中心极限定理.

独立同分布的中心极限定理. $\{X_n\}$ 为独立同分布的 r.v. 有 $E(X_k) = \mu, D(X_k) = \sigma^2$:

$\lim_{n \rightarrow \infty} Z_n = \frac{\sum X_k - n\mu}{\sqrt{n}\sigma}, \lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \phi(x)$.

即 $X_1 + \dots + X_n \sim N(n\mu, n\sigma^2)$.

其中 $Y = \frac{1}{n} \sum X_k$ 在 $n \rightarrow \infty$ 时,

$\lim_{n \rightarrow \infty} E(Y) = D(Y) + [E(Y)]^2$ (因 $Y = \bar{X}_n$ 的定义)

例 某单位电话机有 100 部电话, 在所有通话中有 96% 的话是在各台机中进行的, 假设每台机的忙音打外线是相互独立的, 问需要多少部机才能以 95% 的概率保证每个机的忙音不超过 10%

解 令 X_k 表示第 k 台机的忙音, $k = 1, 2, \dots, 100$

$\lim_{n \rightarrow \infty} P(X_k \leq 1) = 0.96$

$\Rightarrow p = 0.96, np = 0.96 \times 100 = 96$

$\Rightarrow P(N(96, 96)) \approx 0.95$

$\Rightarrow \Phi(\frac{10 - 96}{\sqrt{96}}) \approx 0.95$

$\Rightarrow z = 2.32, N = 28$

→ 检查布-拉普拉斯: $\{Y_n\}$ 为参数 n, p 的二项分布 r.v. 有

$\lim_{n \rightarrow \infty} P\left\{ \frac{Y_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \phi(x)$.

(因 Y_n 服从二项分布, $Y_n = X_1 + X_2 + \dots + X_n$)

⑥ 球理统计基础

→ 研究整体推断规律，{整体 $X \sim F(x)$, 个体 x 的分布}.

自由 n 个个体(样本) 得 $x_1 \sim x_n$ 为样本，乙属性 {^{双尾}_{一尾}: 独立同分布 μ
后: n 个个体观察值之和}.

注意：总体包含的个体数，有限总体 / 无限总体。

→ 统计量： X_i 为样本，若函数 $g(x_1, \dots, x_n)$ 不含任何未知参数，则称为统计量。

常见统计量： $\bar{x} = \frac{1}{n} \sum x_i$, $S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$.

$$A_k = \frac{1}{n} \sum x_i^k \quad (k \text{ 为介于 } 1 \text{ 和 } n \text{ 之间的整数}), \quad B_k = \frac{1}{n} \sum (x_i - \bar{x})^k \quad (k \text{ 为介于 } 1 \text{ 和 } n \text{ 之间的整数}).$$

$$\text{且有: } E(\bar{x}) = \mu, \quad D(\bar{x}) = \frac{\sigma^2}{n}, \quad E(S^2) = \sigma^2 \quad (\text{样本方差期望}).$$

→ N 的特征点： $N(\mu, \sigma^2)$ 的特征点为 u_α . 

→ χ^2 分布。 X_i 为 $\lambda = \text{U}(0, 1)$ 指定。 $\sum X_i^2 = X_1^2 + \dots + X_n^2$ 服从自由度 n 的 χ^2 分布。

(即 $X^2 \sim \chi^2(n)$) \rightarrow 若为 $N(\mu, \sigma^2)$, 则 $\frac{X_i - \mu}{\sigma} \sim N(0, 1)$ 之 \Rightarrow 


且 \exists 加, $\begin{cases} X_1^2 + \dots + X_{n_1}^2 \sim \chi^2(n_1) \\ Y_1^2 + \dots + Y_{n_2}^2 \sim \chi^2(n_2) \end{cases} \Rightarrow X_1^2 + \dots + X_{n_1}^2 + Y_1^2 + \dots + Y_{n_2}^2 \sim \chi^2(n_1 + n_2)$

$$\text{且 } E(\chi^2) = n, \quad D(\chi^2) = 2n.$$

$\chi^2(n)$ 的分布称之为 $\chi^2(n)$.


→ t 分布。设 $X \sim N(0, 1)$, $T \sim \chi^2(n)$, 且 X, T 独立, $\{t = \frac{X}{\sqrt{T/n}}$, 服从自由度为 n 的 t 分布, 记为 $t(n)$.

$$n=2 \text{ 时, } E(T)=1, \quad D(T)=\frac{n}{n+2}.$$



$t(n)$ 的分布称之为 $t(n)$.

→ F 分布。设 $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, 且 U, V 独立, $F = \frac{U/n_1}{V/n_2}$ 为 n_1, n_2 的 F 分布。



$F(n_1, n_2)$ 的分布称之为 F_{n_1, n_2} .

$$\text{且有“互反”公式, } F_{n_1, n_2} = \frac{1}{F_{1-\alpha}(n_2, n_1)}$$

↓ next.

→ 五个抽样分布定理。

① 定理 1: $\bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \Rightarrow \text{Res } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$.

推导: $\bar{X} = \frac{1}{n}(x_1 + \dots + x_n), E(\bar{X}) = n \cdot \frac{1}{n}\mu = \mu$

$$D(\bar{X}) = n \cdot \frac{1}{n^2} \cdot \sigma^2 = \frac{\sigma^2}{n}$$

② 定理 2: $X \sim N(\mu, \sigma^2), \bar{X}, S^2$ 为样本均值 / 方差

Res $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 且 \bar{X}, S^2 独立.

推导: $S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2, (n-1)S^2 = \sum_{i=1}^n [x_i - \mu - (\bar{x} - \mu)]^2$
 $= \sum (x_i - \mu)^2 - 2 \sum (x_i - \mu)(\bar{x} - \mu) + n(\bar{x} - \mu)^2$
 $= 2 \cdot (\bar{x} - \mu) \cdot (\sum x_i - n\mu) = 2(\bar{x} - \mu)(n \cdot \bar{x} - n\mu)$
 $= \sum (x_i - \mu)^2 - n(\bar{x} - \mu)^2$

$$\text{Res } \frac{(n-1)S^2}{\sigma^2} = \sum \frac{(x_i - \mu)^2}{\sigma^2/n} - \frac{(\bar{x} - \mu)^2}{\sigma^2/n} = \chi^2(n-1)$$

③ 定理 3: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$.

推导: $T = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$.

Res $\frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim t(n-1)$ (注意 $\frac{\bar{X}}{\sigma/\sqrt{n}} \sim N(0, 1)$ 的区别).

Op: $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \Rightarrow \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$.

④ 定理 4: $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$. (σ_1, σ_2 不同时).

推导: $\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1), \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1)$.

Res 每: $\frac{\frac{(n_1-1)S_1^2}{\sigma_1^2} / (n_1-1)}{\frac{(n_2-1)S_2^2}{\sigma_2^2} / (n_2-1)} \sim F(n_1-1, n_2-1)$.

⑤ 定理 5: $\frac{(\bar{X} - \bar{\mu}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), S_w = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{(n_1+n_2-2)}$

推导: $\bar{X} - \bar{\mu} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$.

Res $\frac{(\bar{X} - \bar{\mu}) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0, 1)$. (第 6 回为前半部分).

由定理 3/8, $\frac{(\bar{X} - \bar{\mu}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$.

⑦ 多参数估计

1. 点估计

→ 定义：抽样统计量 $\theta(x_1, \dots, x_n)$ 称为参数 θ 的估计量。

↪ 简单 $X \sim F(x; \theta_1, \dots, \theta_m)$, θ_i 未知参数, X_i 为样本。

设 $\theta = (\theta_1, \dots, \theta_m)$, 则 $\exists X \sim F(x; \theta)$, θ 未知即为“参数空间” Θ .

→ 经估计量。若 $X \sim F(x; \theta_1, \dots, \theta_n)$, 且 $\alpha_k = E(X^k)$ 存在

由系统大数定律和样本 k 阶矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \alpha_k = E(X^k)$.

即对任意 n , $A_k \approx \alpha_k = E(X^k)$.

且给定 θ 时估计量 $\hat{\theta}$.

eg. $X \sim U(a, b)$ 的均值分布, a, b 是估计量。
 $d_1 = E(X) = a + \frac{b-a}{2}$, $d_2 = E(X^2) = a^2 + \frac{b^2 - a^2}{3}$.
 $\begin{cases} a = d_1 - \sqrt{3(d_2 - d_1^2)}, \\ b = d_1 + \sqrt{3(d_2 - d_1^2)}. \end{cases}$
 $\text{且 } A_1 = \frac{1}{n} \sum_{i=1}^n X_i, A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ 代替 d_1, d_2 .

→ 常数大数定律。若 $P(X=x) = p(x; \theta)$, $L(\theta) = P(X_1=x_1, \dots, X_n=x_n) = \prod_{i=1}^n p(x_i; \theta)$.

且 $L(\theta)$ 的极大值 $\hat{\theta}(x_1, \dots, x_n)$, 称最大似然估计 (MLE Value), ($X \rightarrow \hat{x}_1, \dots, \hat{x}_n$)

(eg, 发生什么, 就用什么去算).

↓ 采取自然对数, $\ln L(\theta) = \sum \ln p(x_i; \theta)$, 故 $\frac{\partial \ln L}{\partial \theta} = 0$ 为极值.

↓ 若 $\frac{\partial \ln L}{\partial \theta_i} = 0$ 为极值点,

又如若无偏无解, 则 $X \sim U(a, b)$ 不MLE, 但有解.

且小的极限发生在 $X_{(1)} = \hat{a}$, 大的极限发生在 $X_{(n)} = \hat{b}$.

2. 估计量评价标准

→ 无偏性, $E_\theta(\hat{\theta}) = \theta$, 为无偏估计. ($\lim_{n \rightarrow \infty} \ln(\hat{\theta}) = 0$, 即 $\hat{\theta}$ 为无偏)

↪ eg. 若 $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = S^2$, $E(\hat{\mu}) = E(\bar{x}) = \mu$, $E(\hat{\sigma}^2) = E(S^2) = \sigma^2$, 为无偏。

↓ 且样本方差 $\hat{S}^2 = \frac{n-1}{n} S^2$, $E(\hat{S}^2) = \frac{n-1}{n} \sigma^2 \rightarrow \sigma^2$, 仅渐近无偏。

↓ min/max 且无偏无解性成立:

$X \sim U(0, \theta)$, 则 $\hat{\theta}_L = X_{(n)} = \max X_i$.

$f_{\max}(z) = [f(z)]^n$, $f_{\max}(z) = n f(z) (f(z))^{n-1}$.

$E(\hat{\theta}_L) = \int_{-\infty}^{\infty} z \cdot f_{\max}(z) dz$.

→ 有效性: 方差小的更好. ($D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 更有效)

↪ $X \sim U(0, \theta)$, $\hat{\theta}_m = 2\bar{x}$, $\theta = \frac{n+1}{n} X_{(n)}$ 为无偏 (由无偏)

$$D_\theta(\hat{\theta}_m) = 4 \cdot D_\theta(\bar{x}) = \frac{4}{n} \cdot D_\theta(X) = \frac{4}{n} \cdot \frac{\theta^2}{12}$$

$$D_\theta(\hat{\theta}) = \frac{(n+1)^2}{n^2} D_\theta(X_{(n)}) = \frac{(n+1)^2}{n^2} \int_0^\theta (z - \frac{n}{n+1}\theta)^2 \cdot n \cdot \frac{1}{\theta} \cdot \frac{1}{\theta} dz$$

$$D(\hat{\theta}) = E(X - E(X))^2$$

$$f_{\max}(z) = \theta f(z) \cdot [f(z)]^{n-1}, f(z)^2 \int_0^\theta \frac{1}{\theta} dz = \frac{2}{\theta}$$

→ 指合性. $\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} = 0$, $\hat{\theta}_n \xrightarrow{P} \theta$. ($\hat{\theta}_n \xrightarrow{P} \theta$, $n \rightarrow \infty$).

統計學 - 各項之和. 累計不完全函數, 先後出相減.

2. 区間估計.

① 單正态整体, θ 級. 在 μ .

$$X \sim N(\mu, \sigma^2), P\{\bar{X} - c < \mu < \bar{X} + c\} = 1 - \alpha.$$

$$\downarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n}), \text{ 由 } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), P\{-t_{1-\frac{\alpha}{2}} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < t_{1-\frac{\alpha}{2}}\} = 1 - \alpha.$$

由 $\mu \in (\bar{X} - \frac{t_{1-\frac{\alpha}{2}}}{\sqrt{n}/\sigma}, \bar{X} + \frac{t_{1-\frac{\alpha}{2}}}{\sqrt{n}/\sigma})$ 为 μ 的置信水平为 $1 - \alpha$ 的置信区间.

② 單正态整体, θ 級. 在 μ .

$$\text{置信 } \delta, \text{ 由 } \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1), P\{-t_{1-\frac{\alpha}{2}}(n-1) < \frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{1-\frac{\alpha}{2}}(n-1)\} = 1 - \alpha.$$

$$\text{由 } \mu \in (\bar{X} - \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1), \bar{X} + \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)),$$


$$\downarrow \text{若為側, 由單側置信上界 } \bar{\mu} = \bar{X} + \frac{s}{\sqrt{n}} t_{1-\alpha}(n-1), \\ \text{下界 } \underline{\mu} = \bar{X} - \frac{s}{\sqrt{n}} t_{1-\alpha}(n-1).$$

③ 單正态整体, θ^2, μ 級. 在 θ^2 (置信, 置信半徑). 由 χ^2 分佈 (參見 $-V$).

$$\text{不 } \xi \mu, \text{ 由 } \frac{(n-1)s^2}{\theta^2} \sim \chi^2(n-1),$$

$$\text{由 } P\left\{\chi_{\frac{\alpha}{2}}^2(n-1) < \frac{(n-1)s^2}{\theta^2} < \chi_{1-\frac{\alpha}{2}}^2(n-1)\right\} = 1 - \alpha.$$

$$\theta^2 \in \left[\frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}\right], \text{ 置信水準 } 1 - \alpha. \quad \rightarrow \text{p.s.: 由 } \theta^2 \mu \xi 0, \text{ 不 } \theta^2.$$



$$\text{由 } \sum \left(\frac{x_i - \mu}{\theta}\right)^2, \text{ 由 } X^2 \text{ 分佈.}$$

④ 双正态整体, θ_1^2, θ_2^2 級. 在 $\mu_1 - \mu_2$.

$$\text{由 } \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\theta_1^2}{n_1} + \frac{\theta_2^2}{n_2}}} \sim N(0, 1).$$

$$\text{由 } ((\bar{X} - \bar{Y}) - \mu_1 + \mu_2) \pm t_{1-\frac{\alpha}{2}} \sqrt{\frac{\theta_1^2}{n_1} + \frac{\theta_2^2}{n_2}}, (\bar{X} - \bar{Y}) + t_{1-\frac{\alpha}{2}} \sqrt{\frac{\theta_1^2}{n_1} + \frac{\theta_2^2}{n_2}}.$$

⑤ 双正态整体, X, Y 級. θ^2 級. 在 $\mu_1 - \mu_2$.


$$\text{由 } \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2), S_w^2 = \frac{(n_1 - 1)\theta_1^2 + (n_2 - 1)\theta_2^2}{(n_1 + n_2 - 2)},$$

$$t_{1-\frac{\alpha}{2}}((\bar{X} - \bar{Y}) \pm t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2) \cdot S_w \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}})$$

⑥ 双正态整体. $\mu_1, \theta_1^2, \mu_2, \theta_2^2$ 級. 在 θ_1^2 / θ_2^2 .

$$\text{由 } \frac{\theta_1^2 / \theta_2^2}{\theta_2^2 / \theta_1^2} = \frac{\theta_1^2 / S_w^2}{\theta_2^2 / S_w^2} \sim F(n_1 - 1, n_2 - 1).$$

$$\text{由 } 1 - \alpha \text{ 的 } F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1), \frac{\theta_1^2}{\theta_2^2} \cdot \frac{1}{F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)}.$$



⑧假设检验

→ 原假设 H_0 , 备择假设 H_1 .

原理: ① 保护原假设, 结构 A 比结构 B 更合理 $\Rightarrow H_0 = A$.

② 原假设的证据不足 (e.g. 无显著) \rightarrow 拒绝即明显理由支持备择.

③ 原假设简单的. ④ 取与“类似”——“相反的”(既反义反证法).

→ 模式: ① 假设: e.g. $H_0: \mu = 0$, $H_1: \mu \neq 0$.

② 给出统计量, 通过以拒绝对. (Err I: 犯真, Err II: 犯假假设 H_0),

③ 使 P 值变小, 少于 α (显著水平). \rightarrow “ H_0 真, 但拒绝 H_0 的概率”

④ $P_{\text{ rej}} P(\text{弃真}) = \alpha$ 即 P 值, 得拒绝理由.

⑤ 用 \bar{x}, s^2 等数据情况, 在拒绝域中即拒绝原假设

→ 假设: 差 / 6^2 为 0 / $\mu_0 \Rightarrow$ 不显著

单边: $H_0: \mu \geq 0$, $H_1: \mu < 0$.

差 / 6^2 为 0 / $\mu \Rightarrow$ 不显著

如“明显提升”

差 / $\mu_0, 6^2$ 为 0 / $6^2 \Rightarrow \chi^2(n-1)$ 检验

双边: $H_0: \mu = 0$, $H_1: \mu \neq 0$.

差 / $\mu_0, 6^2$ 为 0 / $6^2 \Rightarrow \chi^2(n)$ 检验.

如“是否显著”“是否不同”

(阅) $E\left(\frac{(X_i - \mu)}{6}\right)^2 \sim \chi^2(n)$ (Q).

双 / $6^2, 6^2$ 为 0 / $\mu_1 - \mu_2 = 0$ 不显著. $\left(\frac{(\bar{X} - \bar{P}) - (\mu_1 - \mu_2)}{\sqrt{\frac{6^2}{n_1} + \frac{6^2}{n_2}}}\right)$

双 / $6^2 = 6_1^2 + 6_2^2$ 为 0 / $\mu_1 - \mu_2 = 0$ 不显著. $\left(\frac{(\bar{X} - \bar{P}) - (\mu_1 - \mu_2)}{\sqrt{\frac{6_1^2}{n_1} + \frac{6_2^2}{n_2}}}\right)$ (e.g. 新工艺提高浓度, $\mu_1 - \mu_2$ 增加)

双 / μ_1, μ_2 为 0 / $\frac{6_1}{6_2}$ 不显著. ($\frac{s_1^2}{s_2^2}$). (e.g. 加工精度提高: $\frac{6_1}{6_2}$, 单边).

